

ACL 2025 · Long Papers

Tái lập & Mở rộng

Phân tách chủ đề văn bản tiếng Việt bằng cách xử lý tín hiệu ngữ nghĩa

Tái lập, Đánh giá và Đề xuất Ứng dụng của Semantic Signal Separation

Lớp CS2308.CH203 - Chuyên đề nghiên cứu và ứng dụng về Xử lý ngôn ngữ tự nhiên

GVHD TS. Nguyễn Văn Kiệt

Nhóm 7 Đình Trọng Hậu · Vũ Ánh Minh · Trần Đình Thiện · Ngô Quang Huy

Nội dung trình bày

1

S^3 là gì?

Pipeline tổng thể, 6 bước, 3 biến thể β

2

Tái lập cho tiếng Việt

pyvi tách từ, CafeBERT vs multilingual-E5

3

Thiết lập & kết quả thực nghiệm

4 corpus VN, Concept Compass, coherence & diversity, tốc độ

4

Đánh giá thực tế


AUC trực ICA, ViSFD, VTSNLP, ảnh hưởng n_topics

5

Ứng dụng thực tế

Dashboard phát hiện bất thường + định tuyến câu hỏi ngân hàng — cả hai chạy thật

Pipeline S³ tổng thể



$$\mathbf{X} = \mathbf{A} \cdot \mathbf{S}$$

X = embedding tài liệu · **A** = trục topic · **S** = tỷ lệ topic/tài liệu

$$\mathbf{W} = \mathbf{V} \cdot \mathbf{C}^T \quad (\mathbf{C} = \mathbf{A}^+)$$

W = tọa độ từ trên trục topic · **V** = embedding từ điển

Thuật toán S³ — 6 bước

① Mã hoá tài liệu

Encoder → ma trận **X**

② FastICA

Phân rã **X = A · S**

③ Mã hoá từ vựng

Cùng encoder → **V**

④ Ma trận giải trộn

C = A⁺ (Moore–Penrose)

⑤ Chiếu từ lên trục


W = V · C^T

⑥ Word importance β

Top-k từ mô tả mỗi topic

ĐIỂM ÂM — ĐẶC TRƯNG RIÊNG CỦA S³

β có thể âm → mỗi trục có **định nghĩa âm** (đối lập chủ đề). LDA/BERTopic không làm được.



$$a) \beta_{ax|t} = v_t$$

$$b) \beta_{ang|t} = \frac{v_t}{||v||}$$

$$c) \beta_{com|t} = \frac{(v_t)^3}{||v||}$$

Hình 1 — Trực giác hình học: axial / angular / combined

① AXIAL

$\beta = W_{jt}$ — Coherence cao

② ANGULAR

$\beta = W_{jt}/||W_j||$ — Diversity cao

③ COMBINED ✓ mặc định

$\beta = (W_{jt})^3/||W_j||$ — Mũ lẻ giữ dấu

Tiền xử lý: tách từ tiếng Việt với pyvi

VẤN ĐỀ — CountVectorizer mặc định vỡ từ ghép

"trày xước" → tách theo khoảng trắng → "trày" + "xước" — hai âm tiết vô nghĩa riêng lẻ
→ Bước mã hoá từ vựng V ($W = V \cdot C^T$) cho kết quả sai

```
# Tiền xử lý bắt buộc cho tiếng Việt
from pyvi import ViTokenizer

segmented = [ViTokenizer.tokenize(doc) for doc in documents]
# "trày xước" → "trày_xước" (CountVectorizer giữ _ là ký tự hợp lệ)
```

GIẢI PHÁP — pyvi ViTokenizer

Nối âm tiết bằng `_` → CountVectorizer giữ nguyên là 1 token.

`token_pattern=r"(?u)\b[^\W\d][^\W]*\b"` để giữ underscore.

Thay đổi bắt buộc — paper gốc chỉ thử nghiệm tiếng Anh.

CafeBERT vs multilingual-E5

CafeBERT (uitnlp/CafeBERT)

BERT masked-LM pretrained tiếng Việt.

Không phải sentence embedder → tự cài
masked-mean pooling + L2 normalize.

multilingual-E5-base (intfloat/)

Sentence-transformer thật — pooling &
normalize sẵn.

Thêm prefix "query: " theo convention
E5.

Encoder	Mã hoá 11.122 doc (s)	AUC 1 trục tốt nhất	AUC gộp trục
CafeBERT	34,9	0,689	0,867
E5 multilingual-base ✓	21,9	0,722	0,887
BGE-M3 (đối chứng)	69,6	0,719	0,898

ViSFD · n_topics=40 · AUC trung bình 11 khía cạnh. E5 vừa nhanh hơn 1,6× vừa AUC cao hơn → dùng làm encoder mặc định.

Thiết lập thực nghiệm

Thực nghiệm được chạy trên 4 kho ngữ liệu tiếng Việt, so sánh ba biến thể của S^3 với ba baseline, đo bằng các chỉ số dưới đây, lặp lại trên nhiều seed và nhiều giá trị k để đảm bảo độ tin cậy.


4 KHO NGỮ LIỆU TIẾNG VIỆT		
Corpus	Tài liệu	Loại
Vietnamese-news	858	Tin tức đa chủ đề
UIT-ViSFD	10.000	Review điện thoại, 11 khía cạnh
ViMedical Disease	12.060	Văn bản y tế
VNTC-CNTT	3.571	Chủ đề chuyên ngành CNTT

ĐỘ ĐO		
Metric	Đo gì	Vai trò
WEC-in ↑	Cosine top-term (Word2Vec nội tại)	Chính
Diversity ↑	Tỷ lệ từ khoá không trùng	Chính
C_NPMI	Đồng xuất hiện từ (Gensim)	Phụ
Fit-only (s) ↓	Thời gian fit sau khi embed cache	Tốc độ

Cấu hình: S^3 axial / angular / combined (CafeBERT) · LDA · NMF · BERTopic+UMAP+KMeans
Protocol: $k \in \{10, 20, 30, 40, 50\}$ · 4 seed (11, 29, 42, 47) · **$4 \times 6 \times 5 \times 4 = 480$ run** · không tinh chỉnh siêu tham số

Ví dụ: Visualize các từ vựng hỗ trợ cho trực topic


Từ vựng nổi bật nhất trên hai trục ngữ nghĩa S^3 (visfd, k=50)



Concept Compass — trục hoành = CAMERA (chụp, selfie, camera, cận cảnh...), trục tung = BATTERY (pin trâu, trâu bò...). Mỗi cực lấy 12 từ có điểm chiếu cực trị nhất trên trục đó.

Thiết lập & So sánh Coherence

Coherence (WEC-in) theo số topic, trên 4 corpus tiếng Việt (CafeBERT)



S^3 THẮNG 73% Ô

Trên tổng 80 ô corpus $\times$ seed $\times$ k, S^3 thắng 58 ô — thắng gần tuyệt đối ở ViSFD (18/20), ViMedical (20/20) và VNTC-CNTT (20/20).

NGOẠI LỆ: VIETNAMESE-NEWS

Riêng corpus này, kết quả ngược hoàn toàn — S^3 thua toàn bộ 0/20 ô, LDA và NMF chiếm ưu thế.


DIVERSITY CAO ĐỒNG THỜI

S^3 vẫn giữ diversity cao (0,73–0,76) so với LDA (0,48) và BERTopic (0,43) — không đánh đổi mạch lạc lấy trùng lặp từ khoá.

Hình 2 — WEC-in theo số trục/chủ đề · 4 corpus VN $\times$ 6 mô hình · 480 lần chạy (CafeBERT)

Thiết lập & So sánh tốc độ

Runtime fit-only theo số topic, trên 4 corpus tiếng Việt (CafeBERT)



Mô hình	Fit TB (s)
LDA	28,0
BERTopic	12,5
S ³ (axial/angular/combined)	5,6
NMF	2,1

S³ CHỈ ĐỨNG SAU NMF

Nhanh hơn hẳn LDA (28,0s) và BERTopic (12,5s); chỉ chậm hơn NMF (2,1s) — mô hình duy nhất không cần mã hoá ngữ cảnh, chỉ đếm từ bằng CountVectorizer.

Hình 3 — Fit-only time (thang log), 4 corpus VN × 6 mô hình · 480 lần chạy

Phương pháp đánh giá ứng dụng

GIỚI THIỆU PHƯƠNG PHÁP

Tình trạng hiện tại: các dataset đánh giá (ViSFD, VTSNLP) đã có sẵn các nhãn dữ liệu thật cho từng tài liệu. Nhóm muốn xác định lại xem S^3 có khả năng phát hiện đúng các nhãn dữ liệu đó hay không.

ViSFD

11.122 đánh giá điện thoại · 11 khía cạnh
đa nhãn
(BATTERY, CAMERA, PRICE, SCREEN,
STORAGE...)

VTSNLP

Lấy mẫu 20.000 / 12,17M tài liệu, 25
domain **đơn nhãn**
(Health, Sports, Real_Estate, Business...)

Giới thiệu độ đo ROC-AUC

GIỚI THIỆU ĐỘ ĐO ROC-AUC

ROC-AUC (Receiver Operating Characteristic – Area Under the Curve) đo khả năng phân biệt của một điểm số trên mọi ngưỡng phân loại. **AUC gần 1**: gần như hoàn hảo. **AUC = 0,5**: xếp hạng mang tính ngẫu nhiên. **AUC dưới 0,5**: tệ hơn ngẫu nhiên.

Do dấu một trục ICA là **tuỳ ý** (đảo dấu vẫn là nghiệm tương đương), Nhóm lấy chiều tốt nhất:

$$\text{effective AUC} = \max(\text{AUC}, 1 - \text{AUC})$$

Kết quả AUC — ViSFD & VTSNLP

ViSFD (E5, n_topics=40)

— k=40 cố định để so sánh cross-corpus

Khía cạnh	AUC 1 trực	n tài liệu
CAMERA	0,864	1.043
PRICE	0,830	4.285
SCREEN	0,811	1.540
STORAGE	0,753	132

7 khía cạnh còn lại < 0,75

1 trực tốt nhất: $4 / 11 \geq 0,75$

Gộp 40 trực (logistic CV): $10 / 11 \geq 0,75$

(chỉ OTHERS dưới ngưỡng, AUC = 0,744)

VTSNLP (E5, n_topics=30)

Domain	AUC 1 trực
Real_Estate	0,993
Sports	0,985

... và 19 domain khác $\geq 0,75$ (tổng 21/25)

1 trực tốt nhất: $21 / 25 \geq 0,75$

Gộp 30 trực: $25 / 25 \geq 0,75$


LƯU Ý

VTSNLP đạt AUC cao hơn không phản ánh S^3 hoạt động tốt hơn ở đó, mà do domain của VTSNLP là nhãn đơn — mỗi tài liệu chỉ thuộc đúng một domain, dễ tách bạch hơn ViSFD (một câu có thể đồng thời đề cập PIN và GIÁ).

Ứng dụng 1 — Dashboard phát hiện bất thường

Ý tưởng: suy luận cho tài liệu mới chỉ cần một phép nhân ma trận ($\hat{S} = \hat{X} \cdot C^T$), không cần huấn luyện lại — Nhóm xây dựng một dashboard giám sát theo thời gian thực dựa trên tính chất này.

KỊCH BẢN: PIN ĐIỆN THOẠI QUÁ NHIỆT — 51 bình luận giả lập



Từ khoá trục 1: nóng nóng bỏng nóng hổi tản nhiệt nhiệt

PHÁT HIỆN BẤT THƯỜNG — ỔN

Trục 1 lệch mạnh gấp gần 4 lần trục mạnh thứ nhì, tức tín hiệu bất được rất rõ ràng.

NHƯNG CÒN HẠN CHẾ

Nhãn hiệu chính gán cho trục này là **STORAGE** chứ không phải **BATTERY** (AUC = 0,71) — phát hiện bất thường chính xác, nhưng gán tên khía cạnh chưa chính xác.

Ứng dụng 2 — Định tuyến câu hỏi cho tổng đài ngân hàng

Ý tưởng: dựng một server FastAPI/WebSocket, nạp checkpoint S^3 đã huấn luyện trên bộ UTS2017_Bank (2.471 câu hỏi, 14 nhãn phòng ban thật); mỗi câu hỏi mới được chiếu qua công thức $\hat{S} = \hat{X} \cdot C^T$ để gợi ý phòng ban phù hợp, không cần huấn luyện lại classifier.

Phòng ban	AUC 1 trực	AUC gộp
INTERNET_BANKING	0,848	0,917
CARD	0,830	0,917
LOAN	0,784	0,941
SAVING	0,711	0,755
CUSTOMER_SUPPORT	0,626	0,900
... đủ 12 phòng ban đủ mẫu, xem Bảng 3 trong báo cáo		

1 TRỰC LÀ ĐÃ DÙNG ĐƯỢC
6/12 phòng ban đủ mẫu đạt $AUC \geq 0,75$ chỉ bằng quy tắc đơn giản nhất — lấy điểm của đúng 1 trực, không cần train thêm classifier nào.

GỘP TRỰC LÀ ĐỦ 12/12
Gộp toàn bộ trực bằng hồi quy logistic, cả 12 phòng ban đều vượt ngưỡng — đánh đổi là chi phí tính toán tăng thêm.

HẠN CHẾ THẬT, KHÔNG PHẢI LỖI CÀI ĐẶT
Có vài phòng ban dùng chung một trực, ví dụ CUSTOMER_SUPPORT và INTEREST_RATE cùng rơi vào Topic 13 — đây là giới hạn độ phân giải của model.

Q & A