

S³ cho Tiếng Việt: Tái lập, Đánh giá và Đề xuất Ứng dụng của Semantic Signal Separation

Anonymous ACL submission

Abstract

Semantic Signal Separation (S³) là một phương pháp mô hình hoá chủ đề mới, coi mỗi chủ đề là một trục ngữ nghĩa độc lập được tách ra bằng Independent Component Analysis (ICA) trên không gian embedding ngữ cảnh. Báo cáo này tái lập S³ cho tiếng Việt, so sánh hai encoder (CafeBERT và multilingual-E5), đề xuất một phương pháp đánh giá độ chính xác bằng nhãn thật (điều paper gốc không thực hiện), và thử nghiệm trên hai bộ dữ liệu tiếng Việt (ViSFD, VT-SNLP). Nhóm cũng đề xuất và dựng thử một ứng dụng định tuyến/giám sát dựa trên các trục ngữ nghĩa đã học.

1 Giới thiệu

Với sự bùng nổ dữ liệu văn bản tiếng Việt trên mạng xã hội, sàn thương mại điện tử, và các nền tảng tin tức, nhu cầu tự động khám phá chủ đề/khía cạnh ẩn trong khối lượng lớn văn bản – mà không cần đọc thủ công từng tài liệu – ngày càng cấp thiết cho cả nghiên cứu học thuật lẫn ứng dụng doanh nghiệp (giám sát phản hồi khách hàng, phân loại yêu cầu hỗ trợ...). Các mô hình topic modeling cổ điển (LDA, LSA) và các hướng hiện đại hơn dựa trên embedding ngữ cảnh (CTM, BERTopic, Top2Vec) đều đã được kiểm nghiệm rộng rãi trên tiếng Anh, nhưng gần như chưa có công trình nào đánh giá một cách có hệ thống trên tiếng Việt – một ngôn ngữ đơn lập, viết cách âm tiết, đặt ra thách thức riêng cho các bước tiền xử lý mà hầu hết mô hình mượn nguyên từ tiếng Anh.

Semantic Signal Separation (S³) (Kardos et al., 2025), công bố tại ACL 2025, đề xuất một hướng tiếp cận khác biệt: thay vì coi chủ đề là một cụm tài liệu hay một

phân phối xác suất trên từ vựng, S³ định nghĩa chủ đề như một *trục ngữ nghĩa* độc lập, tách ra từ không gian embedding tài liệu bằng Independent Component Analysis (ICA). Cách tiếp cận này không cần bước đếm từ (BoW/TF-IDF) để tìm chủ đề, chạy nhanh hơn hẳn các baseline thần kinh, và mang lại một tính chất diễn giải độc đáo mà các mô hình khác không có: *định nghĩa âm* của chủ đề (từ khoá cho biết chủ đề *không phải* là gì). Tuy nhiên, mọi thực nghiệm trong paper gốc đều chạy trên các kho ngữ liệu tiếng Anh, và paper cũng chủ động không đánh giá độ chính xác của các trục ngữ nghĩa bằng nhãn thật cho bất kỳ downstream task nào.

Báo cáo này đóng góp trên bốn khía cạnh, đúng theo yêu cầu đề tài. Thứ nhất, nhóm **tái lập S³ cho tiếng Việt** (Mục 3–4 trình bày lại phương pháp và kết quả gốc; Mục 5 là phần thực nghiệm của nhóm), giải quyết một khác biệt kỹ thuật bắt buộc mà paper gốc không gặp phải: tiếng Việt viết cách âm tiết, cần tách từ (word segmentation) trước khi xây từ vựng, nếu không bước chiếu từ lên trục ngữ nghĩa (Công thức 3) sẽ vô nghĩa. Thứ hai, nhóm **so sánh trực tiếp hai encoder** CafeBERT và multilingual-E5 (có thêm BGE-M3 làm đối chứng) về cả tốc độ mã hoá lẫn độ chính xác trục ngữ nghĩa, trên hai bộ dữ liệu tiếng Việt có nhãn thật độc lập: ViSFD (khía cạnh đánh giá điện thoại, đa nhân) và VTSNLP (domain nội dung, đơn nhân). Thứ ba, nhóm đề xuất và triển khai **một phương pháp đánh giá độ chính xác bằng AUC** so trục ICA với nhãn thật – điều paper gốc chủ động không làm – trả lời trực tiếp câu hỏi ”một trục tìm được thuần túy từ phương sai embedding có thực sự trùng khớp với một khái niệm ngữ nghĩa có thật

hay không?”. Thứ tư, nhóm dựng thử **hai ứng dụng chạy thật** dựa trên khả năng suy luận tài liệu mới không cần huấn luyện lại của S^3 (Mục 6): một bảng điều khiển phát hiện bất thường và một server định tuyến câu hỏi cho tổng đài ngân hàng.

Phần còn lại của báo cáo tổ chức như sau: Mục 2 điểm qua các hướng tiếp cận topic modeling hiện có và động lực dẫn tới S^3 ; Mục 3 trình bày chi tiết phương pháp S^3 ; Mục 4 tóm tắt kết quả thực nghiệm của paper gốc; Mục 5 là phần thực nghiệm trọng tâm của nhóm trên tiếng Việt; Mục 6 trình bày hai ứng dụng đề xuất; Mục 7 kết luận và nêu hạn chế.

2 Công trình liên quan

Mô hình hoá chủ đề (topic modeling) là nhóm phương pháp thống kê không giám sát nhằm khám phá các chủ đề ẩn trong một kho văn bản lớn mà không cần đọc thủ công từng tài liệu, mỗi chủ đề thường được biểu diễn bằng một tập từ khoá đại diện. Các phương pháp cổ điển như Latent Semantic Analysis (LSA) (Deerwester et al., 1988) và Latent Dirichlet Allocation (LDA) (Blei et al., 2003) đều xây dựng trên biểu diễn Bag-of-Words (BoW) – đếm tần suất xuất hiện của từ, bỏ qua ngữ pháp và thứ tự từ. LSA nén ma trận đếm từ xuống không gian có số chiều thấp hơn bằng phân tích giá trị kỳ dị (SVD), trong khi LDA là một mô hình sinh xác suất, giả định mỗi tài liệu là một phân phối Dirichlet trên các chủ đề rồi suy luận ngược bằng thống kê Bayes. Cách tiếp cận dựa trên BoW gặp ba hạn chế cố hữu: (i) nhạy cảm với các từ dừng (stop words) có tần suất cao nhưng không mang nội dung, khiến chủ đề sinh ra thường lẫn nhiều từ vô nghĩa; (ii) đòi hỏi một khâu tiền xử lý (loại bỏ từ dừng, chuẩn hoá từ...) không có chuẩn thống nhất, làm giảm khả năng tái lập giữa các nghiên cứu; (iii) biểu diễn BoW rất thưa và có số chiều cao, gây tốn kém tính toán và không nắm bắt được quan hệ ngữ nghĩa giữa các từ đồng nghĩa hoặc đa nghĩa.

Sự xuất hiện của các mô hình biểu diễn ngữ cảnh dựa trên mạng nơ-ron sâu, tiêu biểu là BERT (Devlin et al., 2019) và các biến thể tối ưu cho câu như Sentence-

BERT (Reimers and Gurevych, 2019), mở ra hướng đi mới: biểu diễn tài liệu bằng vector đặc (dense embedding) mang thông tin ngữ cảnh, bền vững hơn trước lỗi chính tả, và tận dụng được học chuyển giao (transfer learning) từ mô hình đã huấn luyện trước trên kho ngữ liệu khổng lồ. Tuy nhiên, bản thân embedding chỉ là một biểu diễn – chưa phải là một mô hình chủ đề – nên các phương pháp xây dựng trên nền tảng này chia thành hai nhánh chính.

Nhánh mạng nơ-ron (neural). Contextualized Topic Models (CTM) (Bianchi et al., 2021) dùng một bộ tự mã hoá biến phân (VAE) nhận đầu vào là embedding ngữ cảnh (có thể kết hợp thêm BoW) để tái tạo lại phân phối từ. ECRTM (Wu et al., 2023) bổ sung một cơ chế điều chuẩn phân cụm embedding (embedding clustering regularization) để buộc các chủ đề tách biệt nhau rõ hơn, còn FASTopic (Wu et al., 2024) mô hình hoá quan hệ tài liệu – chủ đề – từ như một bài toán vận chuyển tối ưu (optimal transport). Điểm chung của các mô hình này là vẫn cần một bộ giải mã hoặc hàm mất mát định nghĩa trên không gian BoW, nên preprocessing nặng vẫn là một khâu khó tránh; đồng thời quá trình huấn luyện lặp (nhiều epoch, tối ưu hoá hai giai đoạn) khiến tốc độ chạy chậm và kết quả có thể không ổn định giữa các lần chạy.

Nhánh phân cụm (clustering). Top2Vec (Angelov, 2020) và BERTopic (Grootendorst, 2022) đi theo hướng hình học: dùng UMAP (McInnes and Healy, 2018) để giảm chiều embedding xuống một không gian vài chục chiều, sau đó dùng HDBSCAN (Campello et al., 2013) để phân cụm mật độ (density-based clustering) mà không cần định trước số cụm. Chủ đề của mỗi cụm được suy ra hậu kỳ: Top2Vec dùng độ tương đồng cosine giữa embedding từ và tâm cụm, còn BERTopic dùng một biến thể TF-IDF theo lớp (class-based TF-IDF) – tức là vẫn quay lại đếm từ ở bước cuối cùng. Pipeline hai giai đoạn này (UMAP rồi HDBSCAN) có tổng cộng 5–6 siêu tham số không có hướng dẫn lựa chọn rõ ràng, số cụm sinh ra không kiểm soát được (có thể cần

thêm bước gộp cụm), và một tài liệu bị phân sai cụm ở bước UMAP sẽ không thể sửa được ở các bước sau.

Ba thách thức chung. Nhìn xuyên suốt cả hai nhánh, các mô hình chủ đề ngữ cảnh hiện có đối mặt với ba vấn đề: (1) nhạy cảm với lựa chọn siêu tham số, khiến kết quả khó tái lập; (2) vẫn phụ thuộc vào một hình thức đếm từ nào đó (BoW trong decoder của CTM, hay TF-IDF trong BERTopic), nên chưa thực sự thoát khỏi hạn chế của cách tiếp cận cổ điển; (3) chưa có bằng chứng rõ ràng cho thấy các mô hình này tận dụng được thông tin ngữ cảnh thật sự, vì phần lớn được đánh giá trên dữ liệu đã qua tiền xử lý kỹ lưỡng. Ba thách thức này chính là động lực trực tiếp dẫn tới Semantic Signal Separation (S^3) (Kardos et al., 2025) – phương pháp mà nhóm tái lập và mở rộng cho tiếng Việt trong báo cáo này, được trình bày ở Mục 3.

3 Phương pháp: Semantic Signal Separation

Ý tưởng cốt lõi. Khác với các mô hình được điểm qua ở Mục 2 – vốn coi chủ đề là một phân phối xác suất trên từ vựng (LDA) hoặc một cụm tài liệu (BERTopic, Top2Vec) – S^3 (Kardos et al., 2025) định nghĩa lại chủ đề như một *trục ngữ nghĩa* (semantic axis): một hướng trong không gian embedding mà dọc theo đó, ý nghĩa của văn bản biến thiên độc lập với các hướng khác. Định nghĩa này lấy cảm hứng trực tiếp từ bài toán kinh điển trong xử lý tín hiệu gọi là “cocktail party problem”: khi nhiều nguồn âm thanh trộn lẫn vào nhau ở micro, Independent Component Analysis (ICA) (Jutten and Herault, 1991; Hyvärinen and Oja, 2000) có thể tách ngược lại các nguồn gốc độc lập chỉ từ tín hiệu trộn quan sát được, không cần biết trước nguồn nào phát ra gì. S^3 áp dụng đúng nguyên lý đó cho embedding văn bản: coi mỗi embedding tài liệu là một “bản trộn” của nhiều tín hiệu ngữ nghĩa độc lập (mỗi tín hiệu là một chủ đề), rồi dùng ICA để tách các tín hiệu đó ra.

Quy trình sáu bước. Gọi $X \in \mathbb{R}^{n \times d}$ là ma trận embedding của n tài liệu (mỗi hàng là vector d chiều do một mô hình encoder

ngữ cảnh sinh ra, ví dụ Sentence-BERT). S^3 tìm chủ đề qua sáu bước:

(1) **Mã hoá tài liệu:** dùng một encoder câu để biến n tài liệu thành ma trận X .

(2) **Phân rã ICA:** áp dụng FastICA lên X để thu được

$$X = AS, \quad (1)$$

trong đó $S \in \mathbb{R}^{n \times k}$ là ma trận k thành phần độc lập (mỗi cột là một trục ngữ nghĩa – một “chủ đề”), còn $A \in \mathbb{R}^{d \times k}$ là ma trận trộn (mixing matrix) biến các trục ngữ nghĩa trở lại không gian embedding gốc.

(3) **Mã hoá từ vựng:** dùng cùng encoder ở bước (1) để mã hoá toàn bộ từ vựng của kho ngữ liệu thành ma trận $V \in \mathbb{R}^{m \times d}$ (m là số từ).

(4) **Ma trận giải trộn:** tính giả nghịch đảo Moore–Penrose của A ,

$$C = A^+, \quad (2)$$

đóng vai trò ánh xạ ngược từ không gian embedding về không gian trục ngữ nghĩa.

(5) **Chiếu từ lên trục ngữ nghĩa:** dùng chính ma trận giải trộn C để chiếu embedding từ vựng V sang cùng không gian k chiều với các trục chủ đề,

$$W = VC^T, \quad W \in \mathbb{R}^{m \times k}. \quad (3)$$

(6) **Chấm điểm quan trọng của từ:** với mỗi trục t , sắp xếp các từ theo một trong ba công thức importance (trình bày dưới đây) tính từ cột t của W , để chọn ra từ khoá đại diện cho chủ đề t .

Vì bước (2) chỉ cần chạy FastICA – một thuật toán hội tụ nhanh, không lặp qua nhiều epoch như huấn luyện mạng nơ-ron – toàn bộ pipeline có độ phức tạp thấp hơn hẳn CTM hay ECRTM, và không cần bất kỳ bước đếm từ (BoW/TF-IDF) nào để tìm chủ đề: từ vựng chỉ được dùng ở bước (3)–(5) để diễn giải các trục đã tìm được. Nhóm dùng cấu hình

FastICA đúng theo Appendix C.1 của paper gốc (algorithm="parallel", whiten="unit-variance", whiten_solver="svd"), triển khai qua thư viện mã nguồn mở turftopic do chính nhóm tác giả S³ công bố – nhóm dùng lại thư viện này cho cả tái lập lần thực nghiệm tiếng Việt ở Mục 5.

Ba công thức chấm điểm quan trọng của từ. Gọi W_{jt} là toạ độ của từ j trên trục t (phần tử hàng j , cột t của W), và $\|W_j\|$ là độ dài vector embedding đã chiếu của từ j trên toàn bộ k trục (hình chiếu của từ đó lên mọi chủ đề, không riêng trục t). Hình 1 minh hoạ trực giác hình học của ba công thức mà S³ đề xuất:

$$\beta_{ax|t} = W_{jt}, \quad (4)$$

$$\beta_{ang|t} = \frac{W_{jt}}{\|W_j\|}, \quad (5)$$

$$\beta_{com|t} = \frac{(W_{jt})^3}{\|W_j\|}. \quad (6)$$

Công thức *axial* (4) chỉ lấy toạ độ thô trên trục t , ưu tiên các từ có hình chiếu lớn nhất bất kể từ đó còn liên quan mạnh đến các trục khác hay không. Công thức *angular* (5) chuẩn hoá theo góc Θ giữa vector từ và trục t (xem Hình 1), ưu tiên các từ mà gần như toàn bộ ý nghĩa nằm dọc trục t , nhưng dễ bị nhiễu bởi các từ hiếm có $\|W_j\|$ rất nhỏ. Công thức *combined* (6) – được paper gốc chọn làm mặc định và cũng là công thức nhóm dùng xuyên suốt báo cáo này – lấy lũy thừa bậc ba của W_{jt} (giữ nguyên dấu vì số mũ lẻ, đồng thời khuếch đại các giá trị lớn) rồi chuẩn hoá theo $\|W_j\|$ như công thức angular, dung hoà giữa hai thái cực trên.

Ý nghĩa âm: một chủ đề không chỉ được định nghĩa bởi những gì nó là. Vì β có thể âm, mỗi trục ngữ nghĩa mang theo cả một tập từ có trọng số dương lớn (*định nghĩa dương* – chủ đề là gì) lẫn một tập từ có trọng số âm lớn (*định nghĩa âm* – chủ đề không phải là gì, hay đối lập với nó). Đây là điểm khác biệt rõ rệt so với LDA hay BERTopic, vốn chỉ liệt kê được từ khoá dương (xác suất hoặc tần suất luôn không âm). Bảng 1 minh hoạ điều này trên năm trục đầu tiên mà S³ trích xuất từ một kho




Figure 3: Geometric intuition for different types of word importance scores for S³.

Figure 1: Trực giác hình học của ba công thức chấm điểm quan trọng từ (axial, angular, combined). Tái hiện từ (Kardos et al., 2025).

	Từ trọng số dương	Từ trọng số âm
0	clustering, histograms, clusterings, histogram, classifying	reinforcement, exploration, planning, tactics, reinforce
1	textual, pagerank, litigants, marginalizing, entailment	matlab, waveforms, microcontroller, accelerometers, microcontrollers
2	sparsestmax, denoising, denoising, minimizers, minimizes	automation, affective, chatbots, questionnaire, attitudes
3	rebmigraph, subgraph, subgraphs, graphsage, graph	adversarial, adversarially, adversarialization, adversary, security
4	clustering, estimations, algorithm, dbscan, estimation	cnn, deeppmind, deeplabv3, convnet, deepseenet

Table 1: Năm chủ đề đầu tiên trích xuất từ kho ArXiv ML Papers, mỗi chủ đề đi kèm định nghĩa dương và âm. Tái hiện từ (Kardos et al., 2025).

tóm tắt bài báo ArXiv về Machine Learning: trục 3 chẳng hạn có định nghĩa dương xoay quanh đồ thị (subgraph, graphsage) và định nghĩa âm xoay quanh tấn công đối kháng (adversarial, security) – hai chủ đề khác nhau nhưng cùng nằm trên một trục lưỡng cực, cho thấy chúng có xu hướng loại trừ nhau trong kho ngữ liệu này.

Concept Compass: trực quan hoá hai trục cùng lúc. Vì mỗi từ và mỗi tài liệu đều có toạ độ trên mọi trục, chọn hai trục bất kỳ làm hai trục của một biểu đồ phân tán (scatter plot) cho phép quan sát trực tiếp cách các khái niệm sắp xếp trong không gian ngữ nghĩa hai chiều đó – tác giả gộp gọi công cụ này là *Concept Compass*.

Hình 2 là ví dụ trên cùng kho ArXiv ML Papers, dùng trục 4 ("Deep Learning vs. Algorithms") làm trục tung và trục 1 ("Physical/Biological/Vision vs. Linguistic Problems") làm trục hoành: các từ liên quan đến thị giác máy tính và robot học tụ ở góc trên-trái, các từ liên quan đến embedding và ngôn ngữ tụ ở góc dưới-phải, trong khi các từ thống kê/thuật toán chung tụ dọc trục tung phía trên – một cấu trúc ngữ nghĩa mạch lạc mà không cần bất kỳ nhãn giám sát nào.

Suy luận cho tài liệu mới. Một ưu điểm thực dụng của S^3 là suy luận tọa độ ngữ nghĩa cho một tài liệu chưa từng thấy không đòi hỏi huấn luyện lại mô hình. Với một tài liệu mới được mã hoá thành embedding $\hat{x} \in \mathbb{R}^d$ (hoặc một lô $\hat{X} \in \mathbb{R}^{n' \times d}$), tọa độ trên k trục ngữ nghĩa được suy ra chỉ bằng một phép nhân ma trận với ma trận giải trộn C đã tính ở bước (4):

$$\hat{S} = \hat{X}C^T. \quad (7)$$

Vì Công thức 7 chỉ là một phép nhân ma trận không tốn kém, S^3 có thể suy luận theo thời gian thực cho luồng dữ liệu mới – tính chất mà nhóm khai thác trực tiếp cho đề xuất ứng dụng ở Mục 6.

4 Kết quả thực nghiệm gốc (tóm tắt)

Thiết lập thực nghiệm. Paper gốc đánh giá S^3 trên năm kho ngữ liệu tiếng Anh – ArXiv ML Papers, BBC News, 20 Newsgroups, StackExchange, Wiki Medical – với 20 Newsgroups được chạy ở cả hai biến thể văn bản thô (raw) và đã tiền xử lý (preprocessed) để riêng đo ảnh hưởng của tiền xử lý, tổng cộng sáu bộ dữ liệu thí nghiệm. Bốn mô hình encoder được so sánh, trải từ embedding tĩnh cổ điển đến ngữ cảnh hiện đại: GloVe, all-MiniLM-L6-v2, all-mpnet-base-v2, và intfloat/e5-large-v2. Số lượng trục/chủ đề được quét từ 10 đến 50. Để tránh p-hacking, nhóm tác giả không tinh chỉnh siêu tham số cho bất kỳ mô hình nào và chỉ chạy một lần duy nhất cho mỗi cấu hình – nhóm chúng tôi tái dựng đúng thiết lập này bằng gói topic-benchmark (mã nguồn mở do chính nhóm tác giả S^3 công bố) để có các hình trong mục này. 435

Cách đo chất lượng. Hai tiêu chí chính được dùng: *Diversity* (d) đo mức độ khác biệt giữa các chủ đề (tỷ lệ từ khoá không trùng lặp giữa các topic), và *Coherence* (C) đo mức độ mạch lạc nội tại của từng chủ đề, được tính từ hai thành phần external/internal word-embedding coherence rồi gộp bằng trung bình nhân $\bar{C} = \sqrt{C_{ex} \cdot C_{in}}$. Một chỉ số tổng hợp thứ ba, *Interpretability* $= \sqrt{\bar{C} \cdot d}$, cũng dùng trung bình nhân để phạt nặng mô hình lệch mạnh về một trong hai mặt (đa dạng cao nhưng vô nghĩa, hoặc mạch lạc cao nhưng trùng lặp).

Tốc độ: kết quả nổi bật nhất. Hình 3 là bằng chứng rõ nhất: trên toàn bộ 20 tổ hợp (5 kho $\times$ 4 encoder), thời gian chạy của ba biến thể S^3 (đường xanh dày, gần như trùng nhau vì ba công thức word-importance chỉ khác nhau ở bước hậu xử lý, không ảnh hưởng thời gian phân rã ICA) luôn nằm ở đáy biểu đồ trục tung logarit, cách biệt hàng chục đến hàng nghìn lần so với ECRTM và FASTopic. Paper gốc báo cáo con số cụ thể: S^3 nhanh hơn 4,5 lần so với á quân BERTopic, và nhanh hơn trung bình 27,5 lần so với toàn bộ baseline còn lại – đồng thời đứng đầu về hiệu năng tổng hợp (Interpretability).

Kiểm định thống kê. Với hồi quy tuyến tính dự đoán Interpretability, lấy S^3 (biến thể combined) làm mốc so sánh, paper gốc báo cáo $F = 167.4$, $p < 0.001$, $R^2 = 0.673$ – và hệ số hồi quy của mọi baseline đều âm và có ý nghĩa thống kê, tức S^3 vượt trội các baseline không phải do ngẫu nhiên.

Phát hiện phản trực giác: S^3 hưởng lợi từ văn bản thô. Trong khi mọi mô hình khác đều cải thiện hoặc giữ nguyên chất lượng khi được cho ăn dữ liệu đã tiền xử lý kỹ (loại bỏ stop word, chuẩn hoá...), S^3 là mô hình duy nhất liên tục đạt điểm cao hơn trên văn bản thô so với văn bản đã tiền xử lý. Nhóm tác giả xem đây là bằng chứng gián tiếp mạnh nhất cho thấy S^3 thật sự khai thác được thông tin ngữ cảnh của encoder, thay vì âm thầm quay lại dựa vào tần suất từ giống các mô hình BoW/TF-IDF ẩn bên dưới CTM hay BERTopic. Hình 4 là kết quả nhóm tái dựng cho một trong




Figure 7: Concepts along Semantic Axes Extracted by S³ in ArXiv ML Papers

hai thành phần coherence (external word-embedding coherence) trên cùng bộ thí nghiệm; xu hướng ở thành phần internal tương tự nhưng không trình bày ở đây do giới hạn khuôn khổ.

So sánh định tính và hạn chế do chính tác giả nêu. Trên 20 Newsgroups, quan sát định tính của paper gốc cho thấy chủ đề của LDA và BERTopic thường lẫn nhiều từ chức năng (function words) không mang nội dung, trong khi CTM/ECRTM sinh từ khoá nhiều; Top2Vec và S^3 là hai mô hình duy nhất cho từ khoá sạch và đặc trưng. Bản thân nhóm tác giả cũng nêu rõ một số hạn chế của nghiên cứu gốc: các chỉ số coherence/diversity dựa trên giả định khá mạnh về không gian embedding; phần lớn baseline được cài đặt lại thay vì dùng mã nguồn tác giả gốc; không có bước tinh chỉnh siêu tham số cho bất kỳ mô hình nào; mỗi cấu hình chỉ chạy với một seed ngẫu nhiên.

nhiên; và phát hiện về tính bền vững trước
tiền xử lý (đoạn trên) mới chỉ được kiểm
chứng trên một kho ngữ liệu (20 News-
groups). Đây cũng là những điểm nhóm
chúng tôi lưu ý khi diễn giải kết quả tái lập
ở Mục 5.

5 Thực nghiệm trên tiếng Việt

Bộ dữ liệu. Nhóm thực nghiệm trên hai bộ dữ liệu tiếng Việt có nhãn thật, phù hợp với hai kiểu bài toán khác nhau: (1) **ViSFD** – 11.122 đánh giá điện thoại di động, mỗi câu được gán nhãn khía cạnh đa nhãn (multi-label) trong 11 khía cạnh (BATTERY, CAMERA, DESIGN, FEATURES, GENERAL, OTHERS, PERFORMANCE, PRICE, SCREEN, SER&ACC, STORAGE), phù hợp bài toán phân tích khía cạnh trong đánh giá sản phẩm; (2) **VT-SNLPs** (Vietnamese curated corpus) – kho ngữ liệu quy mô lớn với 12.169.131 tài liệu.




Figure 3: Thời gian chạy (trục tung, thang log, giây) theo số trục/chủ đề, trên 5 kho ngữ liệu (hàng) $\times$ 4 encoder (cột). Ba biến thể S^3 (xanh dương) luôn ở đáy biểu đồ. Nhóm tái dựng bằng cách chạy gói topic-benchmark công khai của tác giả gốc trên cùng thiết lập paper mô tả.

nhóm lấy mẫu ngẫu nhiên 20.000 tài liệu (seed cố định để tái lập) cho khả thi về mặt tính toán, mỗi tài liệu có đúng một nhãn domain thật (đơn nhãn) trong 25 domain (Health, Sports, Real_Estate, Business_and_Industrial...). Việc có nhãn thật độc lập với chính S^3 trên cả hai bộ là điều kiện tiên quyết cho phương pháp đánh giá độ chính xác trình bày ở đoạn dưới.

Tiền xử lý: tách từ tiếng Việt. Khác với tiếng Anh, tiếng Việt viết cách âm tiết bằng khoảng trắng nên một từ ghép nhiều âm tiết (ví dụ "trày xước", "bảo hành") sẽ bị một CountVectorizer thông thường (tách theo khoảng trắng) chặt vụn thành các âm tiết rời rạc vô nghĩa, làm hỏng bước

hoá từ vựng V ở Công thức 2-3. Nhóm dùng pyvi (ViTokenizer) để tách từ trước khi xây từ vựng, nối các âm tiết cùng một từ bằng dấu gạch dưới (trày_xước) để CountVectorizer giữ nguyên là một token duy nhất; danh sách từ khoá hiển thị cho người dùng sau đó được khôi phục lại dấu cách. Đây là một khác biệt bắt buộc so với pipeline gốc của paper (vốn chỉ thử nghiệm trên tiếng Anh) mà nhóm phải tự bổ sung để S^3 hoạt động đúng trên tiếng Việt.

So sánh encoder: CafeBERT vs. multilingual-E5. Đúng theo yêu cầu đề tài, nhóm so sánh trực tiếp hai encoder trên ViSFD ở cùng $n_{topics} = 40$:




Figure 4: External word-embedding coherence theo số trục/chủ đề, trên 5 kho $\times$ 4 encoder – một trong hai thành phần cấu thành $\tilde{C}$. Nhóm tái dựng bằng gói topic-benchmark.

Encoder	Mã hoá (s)	AUC 1 trục	AUC Gộp
CafeBERT	34,9	0,689	0,867
E5 (multilingual-base)	21,9	0,722	0,887
BGE-M3 (đối chứng)	69,6	0,719	0,898

Table 2: So sánh encoder trên ViSFD, $n_{topics} = 40$, 11.122 tài liệu. AUC trung bình trên 11 khía cạnh gốc.

CafeBERT (uitnlp/CafeBERT, tự cài masked-mean pooling) và multilingual-E5 (intfloat/multilingual-e5-base, sentence-transformer chuẩn); BAAI/bge-m3 được thêm làm đối chứng thứ ba. Bảng 2 tổng hợp ba tiêu chí: tốc độ mã hoá (encode toàn bộ 11.122 tài liệu), độ chính xác trung bình khi dùng một trục tốt nhất cho mỗi khía cạnh, và độ chính xác khi gộp tất cả trục bằng hồi quy logistic 5-fold (xem định nghĩa AUC ở đoạn dưới).

Đóng góp vừa nhanh hơn CafeBERT khoảng 1,6 lần, vừa cho AUC cao hơn ở cả hai cách tính. Điều này cho thấy một sentence-transformer đa ngữ tổng quát (không chuyên biệt hoá cho tiếng Việt như CafeBERT) vẫn tạo được không gian embedding phù hợp hơn cho S^3 trên dữ liệu này. BGE-M3 cho AUC gộp trục cao nhất nhưng chậm hơn CafeBERT gấp đôi, chậm hơn E5 gấp ba – đánh đổi không đáng nếu tốc độ là ưu tiên. Vì lý do này, nhóm dùng E5 làm encoder mặc định cho các thực nghiệm còn lại trong mục này.

Đóng góp phương pháp luận: đánh giá độ chính xác bằng nhãn thật. Paper gốc chủ động không đánh giá tỷ lệ chủ đề trong tài liệu (document-topic proportions) cho bất kỳ downstream task nào (Mục 8.6 của paper gốc), vì hai bộ dữ liệu benchmark của paper không có nhãn chủ đề độc lập

để đối chiếu. ViSFD và VTSNLP lấp đúng khoảng trống này: cả hai đều có nhãn con người gán độc lập với S^3 , cho phép nhóm trả lời câu hỏi mà paper gốc không trả lời được – *một trục ICA tìm được thuần túy từ phương sai embedding có thực sự trùng khớp với một khái niệm ngữ nghĩa có thật hay không?* Với mỗi nhãn (khía cạnh ở ViSFD, domain ở VTSNLP), nhóm coi bài toán "tài liệu có mang nhãn này không" như một bài toán phân loại nhị phân, dùng điểm số của tài liệu trên một trục ICA (hoặc tổ hợp tuyến tính mọi trục qua hồi quy logistic) làm điểm phân loại, rồi tính ROC-AUC (0,5 = ngẫu nhiên, 1,0 = hoàn hảo) theo chiều tương quan tốt nhất của trục đó (tương đương $\max(\text{AUC}, 1 - \text{AUC})$), cùng hệ số tương quan điểm-nhị phân (point-biserial r) để kiểm định ý nghĩa thống kê.

Kết quả trên ViSFD ($n_{\text{topics}} = 40$, E5): 4/11 khía cạnh đạt $\text{AUC} \geq 0,75$ chỉ với một trục tốt nhất (CAMERA=0,864, PRICE=0,830, SCREEN=0,811, STORAGE=0,753), nhưng khi gộp toàn bộ 40 trục vào một mô hình hồi quy logistic, con số này tăng lên 10/11 (chỉ OTHERS dưới ngưỡng, $\text{AUC}=0,744$) – cho thấy tín hiệu của một khía cạnh thường trải rộng trên nhiều trục thay vì tập trung ở một trục duy nhất. Trên VTSNLP ($n_{\text{topics}} = 30$, E5), kết quả mạnh hơn hẳn: 21/25 domain đạt $\text{AUC} \geq 0,75$ chỉ với một trục, và toàn bộ 25/25 domain đạt ngưỡng này khi gộp trục, với một số domain gần như tách hoàn hảo (Real_Estate $\text{AUC}=0,993$, Sports $\text{AUC}=0,985$). Nhóm nhấn mạnh đây *không* phải bằng chứng S^3 "hoạt động tốt hơn" trên VTSNLP, mà phản ánh sự khác biệt về bản chất bài toán: domain trong VTSNLP là nhãn đơn (single-label), tách bạch theo chủ đề nội dung – rất gần với định nghĩa "trục ngữ nghĩa" của S^3 ; trong khi khía cạnh trong ViSFD là nhãn đa nhãn (multi-label, một câu có thể vừa nói về PIN vừa nói về GIÁ), nên ranh giới giữa các khía cạnh vốn đã chồng lấn ngay trong chính dữ liệu, không phải do S^3 yếu hơn.

Quét số lượng trục. Bảng 3 tổng hợp Diversity, Coherence và Interpretability tổng hợp (định nghĩa ở Mục 4) khi quét $n_{\text{topics}} \in \{10, 20, 30, 40, 50\}$ trên ViSFD

Dataset	n	Div.	Coh.	Interp.
ViSFD (CafeBERT)	10	0,88	0,855	0,867
	20	0,93	0,866	0,897
	30	0,84	0,833	0,838
	40	0,84	0,866	0,853
	50	0,81	0,856	0,835
VTSNLP (E5)	10	0,97	0,848	0,907
	20	0,98	0,844	0,910
	30	0,99	0,853	0,919
	40	0,985	0,847	0,913
	50	0,99	0,847	0,916

Table 3: Quét số trục n : Diversity, Coherence, Interpretability tổng hợp = $\sqrt{C \cdot d}$ trên ViSFD và VTSNLP.

(CafeBERT) và VTSNLP (E5). Xu hướng chung: diversity gần như không đổi (luôn trên 0,8), trong khi coherence và điểm tổng hợp đạt đỉnh ở một giá trị trung gian ($n_{\text{topics}} = 20$ cho ViSFD, $n_{\text{topics}} = 30$ cho VTSNLP) rồi giảm nhẹ khi n_{topics} tiếp tục tăng. Điều này khớp với trực giác: tăng số trục cho phép tách các khía cạnh hiếm gặp (ví dụ STORAGE ở ViSFD chỉ xuất hiện trong 132/11.122 tài liệu) thành trục riêng, nhưng vượt quá một ngưỡng, các trục mới sinh ra bắt đầu trùng lặp hoặc bám vào biến thể chính tả/nhiều thay vì tín hiệu ngữ nghĩa mới, kéo coherence xuống.

6 Đề xuất ứng dụng

Công thức suy luận tài liệu mới $\hat{S} = \hat{X}C^T$ (Công thức 7) có nghĩa là một checkpoint S^3 đã huấn luyện có thể chấm điểm văn bản mới theo thời gian thực, không cần huấn luyện lại. Nhóm tận dụng tính chất này để dựng thử hai ứng dụng nhỏ, chạy thật (không phải mock) trên các checkpoint đã huấn luyện ở Mục 5.

Ứng dụng 1: Bảng điều khiển phát hiện bất thường. Với một luồng bình luận/đánh giá mới, nhóm tính điểm trung bình theo lô trên từng trục ($\hat{S}$), rồi so với phân phối "bình thường" của trục đó trên tập huấn luyện bằng kiểm định z hai mẫu (độ lệch tính theo sai số chuẩn của trung bình lô). Trục nào có $|z|$ vượt ngưỡng được coi là tín hiệu bất thường; nếu trục đó đã được hiệu chỉnh nhãn ngoại tuyến (offline) qua phương pháp AUC ở Mục 5, cảnh báo còn kèm theo tên khía cạnh diễn

giải được thay vì chỉ "Trục 27". Trên kịch bản mô phỏng một đợt pin điện thoại quá nhiệt/phát nổ (51 bình luận giả lập), hệ thống thật sự bắt được tín hiệu: trục mạnh nhất có $z = -12,79$ (gấp gần bốn lần trục mạnh nhì, $z = -3,27$), với các từ khoá đặc trưng *nóng, nóng bỏng, nóng hổi, tản nhiệt, nhiệt* – đúng chủ đề nhiệt/quá nhiệt của kịch bản. Đáng chú ý, nhãn hiệu chính ngoại tuyến gán cho trục này lại là STORAGE (AUC=0,71) chứ không phải BATTERY – một minh chứng trung thực cho hạn chế đã nêu ở Mục 5: việc phát hiện bất thường (dựa trên độ lệch thống kê thuần túy) hoạt động tốt hơn hẳn việc gán đúng tên gọi con người cho trục đó.

Ứng dụng 2: Định tuyến câu hỏi cho tổng đài ngân hàng. Nhóm dựng một server FastAPI/WebSocket riêng (đóng gói Docker), nạp checkpoint S³ huấn luyện trên UTS2017_Bank (2.471 câu hỏi/phản ánh, 14 nhãn phòng ban thật: CARD, LOAN, SECURITY...), nhận câu hỏi mới qua HTTP, định tuyến bằng đúng phép chiếu $\hat{S} = \hat{X}C^T$ vào trục đã hiệu chỉnh nhãn phòng ban, rồi phát qua WebSocket cho client đang theo dõi đúng phòng ban đó (đã kiểm chứng bằng client thật – server/simulate.py bắn câu hỏi thật lấy từ UTS2017_Bank và so trực tiếp với nhãn thật trên console). Bảng 4 là độ chính xác định tuyến (AUC) đo trên đúng checkpoint server đang dùng ($n_{topics} = 30$): 12/14 nhãn đủ mẫu để kiểm định (ACCOUNT, SECURITY quá ít mẫu), trong đó 6/12 đã đạt $AUC \geq 0,75$ chỉ với quy tắc định tuyến 1-trục hiện dùng trên server (đơn giản, không cần huấn luyện thêm classifier), và toàn bộ 12/12 đạt ngưỡng đó nếu thay bằng hồi quy logistic gộp trục – hướng cải thiện rõ ràng cho bản sau nếu ưu tiên độ chính xác hơn tốc độ triển khai.

Hạn chế đã ghi nhận. Cả hai ứng dụng hiện dùng quy tắc 1-trục đơn giản (không train thêm classifier) để giữ độ trễ thấp và không cần lưu thêm mô hình phụ; Bảng 4 cho thấy đây là đánh đổi thật – AUC gộp trục cao hơn rõ rệt ở gần như mọi nhãn. Một số phòng ban còn dùng chung một trục (ví dụ CUSTOMER_SUPPORT và IN-

Phòng ban (nhãn)	AUC 1 trục	AUC gộp
CARD	0,830	0,917
CUSTOMER_SUPPORT	0,626	0,900
DISCOUNT	0,740	0,858
INTEREST_RATE	0,796	0,918
INTERNET_BANKING	0,848	0,917
LOAN	0,784	0,941
MONEY_TRANSFER	0,806	0,887
OTHER	0,720	0,856
PAYMENT	0,789	0,837
PROMOTION	0,725	0,868
SAVING	0,711	0,755
TRADEMARK	0,726	0,944

Table 4: Độ chính xác định tuyến câu hỏi ngân hàng (AUC) trên UTS2017_Bank, $n_{topics} = 30$ (đúng checkpoint server đang chạy). 12/12 nhãn đủ mẫu vượt ngưỡng 0,75 khi gộp trục.

TEREST_RATE cùng ánh xạ vào Topic 13 ở $n_{topics} = 30$), nghĩa là câu hỏi khớp trục đó sẽ được thông báo cho cả hai phòng ban thay vì định tuyến dứt khoát về một nơi. Đây là hạn chế thật của độ phân giải mô hình ở mức n_{topics} hiện dùng, không phải lỗi cài đặt, và là hướng cải thiện rõ ràng cho các phiên bản sau (tăng n_{topics} , hoặc chuyển sang bộ phân loại gộp trục).

7 Kết luận

Hạn chế

References

- Dimo Angelov. 2020. Top2Vec: Distributed representations of topics.
- Federico Bianchi, Silvia Terragni, and Dirk Hovy. 2021. Pre-training is a hot topic: Contextualized document embeddings improve topic coherence. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*, pages 759–766.
- David M. Blei, Andrew Y. Ng, and Michael I. Jordan. 2003. Latent Dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022.
- Ricardo J. G. B. Campello, Davoud Moulavi, and Jörg Sander. 2013. Density-based clustering based on hierarchical density estimates. pages 160–172.
- Scott C. Deerwester, Susan T. Dumais, Thomas K. Landauer, George W. Furnas, and L. L. Beck. 1988. Improving information retrieval using latent semantic indexing.

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*.
- Maarten Grootendorst. 2022. BERTopic: Neural topic modeling with a class-based TF-IDF procedure.
- Aapo Hyvärinen and Erkki Oja. 2000. Independent component analysis: Algorithms and applications. *Neural Networks*, 13(4):411–430.
- Christian Jutten and Jeanny Herault. 1991. Blind separation of sources, part I: An adaptive algorithm based on neuromimetic architecture. *Signal Processing*, 24(1):1–10.
- Márton Kardos, Jan Kostkan, Kenneth Enevoldsen, Arnault-Quentin Vermillet, Kristoffer Nielbo, and Roberta Rocca. 2025. S³ – semantic signal separation. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 633–666, Vienna, Austria. Association for Computational Linguistics.
- Leland McInnes and John Healy. 2018. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992.
- Xiaobao Wu, Xinshuai Dong, Thong Nguyen, and Anh Tuan Luu. 2023. Effective neural topic modeling with embedding clustering regularization.
- Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. 2024. FASTopic: A fast, adaptive, stable, and transferable topic modeling paradigm.