

S³ cho Tiếng Việt: Tái lập, Đánh giá và Đề xuất Ứng dụng của Semantic Signal Separation

Đình Trọng Hậu, Vũ Ánh Minh, Trần Đình Thiện, Ngô Quang Huy

Giảng viên hướng dẫn: TS. Nguyễn Văn Kiệt

Abstract

Semantic Signal Separation (S³) là một phương pháp mô hình hoá chủ đề mới, coi mỗi chủ đề là một trục ngữ nghĩa độc lập tách ra bằng Independent Component Analysis (ICA) trên không gian embedding. Báo cáo tái lập S³ cho tiếng Việt (bổ sung bước tách từ mà paper gốc không cần), rồi xây dựng một benchmark định lượng riêng gồm 480 lần chạy thật trên bốn kho ngữ liệu tiếng Việt, so S³ với LDA/NMF/BERTopic: S³ dẫn đầu coherence và diversity, đồng thời đạt tốc độ fit chỉ đứng sau NMF nhờ tái sử dụng vocabulary đã mã hoá và suy ba biến thể axial/angular/combined từ một phép phân rã FastICA duy nhất. Nhóm còn so sánh hai encoder (CafeBERT, multilingual-E5), đề xuất một phương pháp đánh giá độ chính xác bằng nhân thật trên ViSFD/VTSNLP – điều paper gốc chủ động không làm – và dựng thử hai ứng dụng chạy thật dựa trên khả năng suy luận tài liệu mới không cần huấn luyện lại của S³.

1 Giới thiệu

Nhu cầu tự động khám phá chủ đề trong văn bản tiếng Việt (mạng xã hội, thương mại điện tử, tin tức) ngày càng lớn, nhưng các mô hình topic modeling hiện có (LDA, LSA, CTM, BERTopic, Top2Vec...) hầu như chỉ được kiểm nghiệm trên tiếng Anh – một ngôn ngữ đơn lập, viết cách âm tiết như tiếng Việt đặt ra thách thức tiền xử lý riêng.

Semantic Signal Separation (S³) (Kardos et al., 2025), công bố tại ACL 2025, định nghĩa chủ đề như một *trục ngữ nghĩa* tách ra từ embedding tài liệu bằng ICA, thay vì một cụm hay một phân phối xác suất trên từ vựng. Cách này không cần đếm từ (BoW/TF-IDF), chạy nhanh hơn baseline

thần kinh trên tiếng Anh, và cho phép *định nghĩa âm* của chủ đề. Tuy nhiên mọi thực nghiệm gốc chỉ chạy trên tiếng Anh, và paper không đánh giá độ chính xác trục ngữ nghĩa bằng nhân thật.

Báo cáo đóng góp trên bốn hướng: (1) **tái lập S³ cho tiếng Việt** (Mục 3), bổ sung bước tách từ tiếng Việt trước khi xây từ vựng; (2) một **benchmark định lượng 480 lần chạy thật** trên bốn kho ngữ liệu tiếng Việt (Mục 4), cho thấy S³ dẫn đầu cả coherence, diversity lẫn tốc độ fit (chỉ sau NMF) khi tái sử dụng vocabulary đã mã hoá; (3) **so sánh hai encoder** CafeBERT và multilingual-E5, cùng một **phương pháp đánh giá độ chính xác bằng AUC** so trực ICA với nhân thật trên ViSFD/VTSNLP – điều paper gốc chủ động không làm (Mục 5); (4) **hai ứng dụng chạy thật** khai thác khả năng suy luận tài liệu mới của S³ (Mục 6).

2 Công trình liên quan

Mô hình hoá chủ đề khám phá chủ đề ẩn trong kho văn bản lớn không cần đọc thủ công. Các phương pháp cổ điển như LSA (Deerwester et al., 1988) và LDA (Blei et al., 2003) xây dựng trên Bag-of-Words (BoW), gặp ba hạn chế cố hữu: nhạy cảm với từ dừng, cần tiền xử lý không chuẩn hoá (khó tái lập), và biểu diễn thưa/nhiều chiều không nắm được quan hệ ngữ nghĩa.

Embedding ngữ cảnh (BERT (Devlin et al., 2019), Sentence-BERT (Reimers and Gurevych, 2019)) mở ra hướng khác: biểu diễn tài liệu bằng vector đặc mang ngữ cảnh. Các mô hình xây trên nền này chia hai nhánh. **Nhánh neural**: CTM (Bianchi et al., 2021) dùng VAE tái tạo phân phối từ từ embedding; ECRTM (Wu

et al., 2023) thêm điều chuẩn phân cụm embedding; FASTopic (Wu et al., 2024) dùng optimal transport – cả ba vẫn cần decoder/hàm mất mát trên không gian BoW nên preprocessing nặng và huấn luyện lặp chậm. **Nhánh clustering:** Top2Vec (Angelov, 2020) và BERTopic (Grootendorst, 2022) dùng UMAP (McInnes and Healy, 2018) giảm chiều rồi HDBSCAN (Campello et al., 2013) phân cụm, suy chủ đề hậu kỳ bằng cosine hoặc class-based TF-IDF – pipeline nhiều siêu tham số, lỗi ở bước UMAP không sửa được ở bước sau.

Cả hai nhánh đối mặt ba vấn đề chung: nhạy siêu tham số (khó tái lập), vẫn phụ thuộc một hình thức đếm từ nào đó (chưa thoát hạn chế cổ điển), và chưa có bằng chứng rõ ràng khai thác được ngữ cảnh thật sự (đánh giá chủ yếu trên dữ liệu đã tiền xử lý kỹ). Đây là động lực trực tiếp dẫn tới Semantic Signal Separation (S³) (Kardos et al., 2025), trình bày ở Mục 3.

3 Phương pháp: Semantic Signal Separation

Ý tưởng cốt lõi. Khác với LDA (phân phối xác suất) hay BERTopic/Top2Vec (cụm tài liệu), S³ (Kardos et al., 2025) định nghĩa chủ đề như một *trục ngữ nghĩa*: một hướng trong không gian embedding mà dọc theo đó ý nghĩa văn bản biến thiên độc lập với các hướng khác – lấy cảm hứng từ ”cocktail party problem” trong xử lý tín hiệu: Independent Component Analysis (ICA) (Jutten and Herault, 1991; Hyvärinen and Oja, 2000) tách các nguồn âm độc lập từ tín hiệu trộn quan sát được, không cần biết trước nguồn nào phát ra gì. S³ áp dụng nguyên lý này cho embedding văn bản, coi mỗi embedding tài liệu là bản trộn của nhiều tín hiệu ngữ nghĩa độc lập.

Quy trình sáu bước. Gọi $X \in \mathbb{R}^{n \times d}$ là embedding của n tài liệu. S³ tìm chủ đề qua: (1) mã hoá tài liệu thành X bằng một encoder câu; (2) phân rã FastICA

$$X = AS, \quad (1)$$

với $S \in \mathbb{R}^{n \times k}$ là ma trận k trục ngữ nghĩa độc lập và $A \in \mathbb{R}^{d \times k}$ là ma trận trộn; (3) mã hoá từ vựng thành $V \in \mathbb{R}^{m \times d}$; (4) giả

ngịch đảo Moore–Penrose

$$C = A^+; \quad (2)$$

(5) chiếu từ lên trục ngữ nghĩa

$$W = VC^T, \quad W \in \mathbb{R}^{m \times k}; \quad (3)$$

(6) chấm điểm quan trọng của mỗi từ trên mỗi trục để chọn từ khoá đại diện. Vì bước (2) chỉ cần FastICA – hội tụ nhanh, không lặp qua nhiều epoch – pipeline không cần đếm từ để tìm chủ đề (từ vựng chỉ dùng ở bước (3)–(5) để *diễn giải*), đơn giản và nhanh hơn CTM/ECRTM về lý thuyết. Nhóm dùng cấu hình FastICA theo Appendix C.1 paper gốc (algorithm=”parallel”, whiten=”unit-variance”, whiten_solver=”svd”), triển khai qua thư viện mã nguồn mở turftopic do chính tác giả S³ công bố – dùng lại cho cả tái lập lần thực nghiệm tiếng Việt ở Mục 5.

Ba công thức chấm điểm quan trọng của từ. Gọi W_{jt} là toạ độ từ j trên trục t , $\|W_j\|$ là độ dài chiều của từ đó lên toàn bộ k trục. Hình 1 minh hoạ ba công thức:

$$\beta_{ax|t} = W_{jt}, \quad (4)$$

$$\beta_{ang|t} = \frac{W_{jt}}{\|W_j\|}, \quad (5)$$

$$\beta_{com|t} = \frac{(W_{jt})^3}{\|W_j\|}. \quad (6)$$

Axial ưu tiên hình chiếu lớn nhất bất kể liên quan tới trục khác; *angular* chuẩn hoá theo góc, ưu tiên từ mà gần như toàn bộ ý nghĩa nằm dọc trục t nhưng dễ nhiễu với từ hiếm ($\|W_j\|$ nhỏ); *combined* – mặc định của paper gốc và của báo cáo này – lấy lũy thừa bậc ba của W_{jt} (giữ dấu, khuếch đại giá trị lớn) rồi chuẩn hoá như angular.

Ý nghĩa âm và Concept Compass. Vì β có thể âm, mỗi trục mang cả định nghĩa dương (chủ đề là gì) lẫn định nghĩa âm (chủ đề *không phải* là gì) – khác biệt rõ so với LDA/BERTopic, vốn chỉ liệt kê được từ khoá dương. Chọn hai trục làm hai chiều của một biểu đồ phân tán (*Concept Compass*) cho phép quan sát trực tiếp cách các khái niệm sắp xếp trong không gian

Coherence (WEC-in) theo số topic, trên 4 corpus tiếng Việt (CafeBERT)




Figure 3: WEC-in (coherence) theo số trục/chủ đề, trên 4 corpus tiếng Việt $\times$ 6 mô hình (CafeBERT). Số liệu và hình của nhóm, từ 480 lần chạy thật trong benchmark/cafebert_full/.

Mô hình	WEC-in	Div.	C_NPMI	Fit (s)
S ³ axial	0,578	0,733	-0,384	5,6
S ³ angular	0,584	0,763	-0,385	5,6
S ³ combined	0,580	0,747	-0,384	5,6
LDA	0,412	0,478	0,080	28,0
NMF	0,456	0,587	0,093	2,1
BERTopic+UMAP+KMeans	0,510	0,429	-0,202	12,5

Table 1: Trung bình trên 480 lần chạy. WEC-in/Diversity: càng cao càng tốt. C_NPMI: chỉ số phụ. Fit: giây, fit-only warm.

của S³ chỉ còn 5,6s trong sáu mô hình – chậm hơn NMF (2,1s, không cần mã hoá ngữ cảnh vì chỉ đếm từ bằng CountVectorizer) nhưng nhanh hơn hẳn BERTopic (12,5s) và LDA (28,0s) (Hình 4). Phần chi phí còn lại của S³ là một lần mã hoá từ vựng mỗi corpus: nếu đo độc lập không tái sử dụng (gọi `fit_transform()` mặc định của `topicmodel` cho từng `seed \times k`), chi phí này tỉ lệ gần như tuyệt đối với kích thước từ vựng ($r = 0,9998, \approx 0,028s/từ$) chứ không phụ thuộc k hay `seed` – đây chính là lý do Nhóm chọn tái sử dụng vocabulary đã mã hoá thay vì gọi lại `fit_transform()` mặc định cho từng `seed \times k`.

Ở cấp độ *pipeline* đầy đủ, cả S³ và BERTopic bị chi phí mã hoá CafeBERT chi phối ($\approx 3,0$ nghìn giây, gần bằng nhau vì cùng encoder), còn LDA/NMF vẫn dưới 30s – chênh lệch giữa *lớp mô hình*, không phải giữa các encoder cùng loại.

5 Thực nghiệm trên tiếng Việt

Bộ dữ liệu và tiền xử lý. Nhóm dùng hai bộ dữ liệu tiếng Việt có nhãn thật độc lập, phù hợp hai kiểu bài toán: **ViSFD** (11.122 đánh giá điện thoại, đa nhãn trên 11 khía cạnh: BATTERY, CAMERA, DESIGN...) và **VTSNLP** (mẫu 20.000/12.169.131 tài liệu,

Runtime fit-only theo số topic, trên 4 corpus tiếng Viet (CafeBERT)




Figure 4: Thời gian fit-only (trục tung, thang log, giây) theo số trục/chủ đề. S^3 chỉ chậm hơn NMF, nhanh hơn hẳn LDA và BERTopic trong sáu mô hình được so sánh.

đơn nhãn trên 25 domain). Vì tiếng Việt viết cách âm tiết, một CountVectorizer thông thường sẽ chặt vụn từ ghép (ví dụ "trầy xước"); nhóm dùng pyvi để tách từ trước khi xây từ vựng V (Công thức 2–3) – khác biệt bắt buộc mà paper gốc (chỉ thử tiếng Anh) không cần.

So sánh encoder. Bảng 2 so CafeBERT, multilingual-E5 và BGE-M3 (đối chứng) trên ViSFD ($k = 40$). E5 nhanh hơn CafeBERT 1,6 lần và cho AUC cao hơn ở cả hai cách tính; BGE-M3 cao nhất nhưng chậm gấp ba E5. Nhóm dùng E5 làm encoder mặc định cho các thực nghiệm còn lại.

Đóng góp phương pháp luận: đánh giá độ chính xác bằng AUC. Paper gốc chủ động không đánh giá tỷ lệ chủ đề trong tài liệu cho bất kỳ downstream task nào (Mục 8.6); ViSFD/VTSNLP lấp khoảng trống này nhờ có nhãn độc lập với S^3 . Với mỗi nhãn, nhóm coi "tài liệu có mang nhãn này không" là bài toán phân loại

nhị phân, dùng điểm trên một trục (hoặc hồi quy logistic gộp mọi trục) làm điểm phân loại, tính ROC-AUC theo chiều tương quan tốt nhất ($\max(\text{AUC}, 1 - \text{AUC})$). Trên ViSFD ($k = 40$, E5): 4/11 khía cạnh đạt $\text{AUC} \geq 0,75$ với một trục, tăng lên 10/11 khi gộp trục bằng hồi quy logistic. Trên VTSNLP ($k = 30$, E5): 21/25 domain đạt ngưỡng với một trục, toàn bộ 25/25 khi gộp trục (Real_Estate=0,993, Sports=0,985) – kết quả mạnh hơn *không* phải vì S^3 "tốt hơn" trên VTSNLP, mà vì domain là nhãn đơn, còn khía cạnh ViSFD là nhãn đa (một câu có thể vừa nói PIN vừa nói GIÁ), vốn đã chồng lấn ngay trong dữ liệu.

Quét số lượng trục. Diversity gần như không đổi theo k (luôn trên 0,8); coherence và điểm tổng hợp Interpretability = $\sqrt{\bar{C} \cdot d}$ đạt đỉnh ở k trung gian ($k = 20$ cho ViSFD, $k = 30$ cho VTSNLP) rồi giảm nhẹ – tăng k giúp tách khía cạnh hiếm (ví dụ STORAGE chỉ 132/11.122 tài liệu) thành trục riêng, nhưng vượt ngưỡng sẽ sinh trục trùng lặp hoặc bám nhiễu thay vì tín hiệu ngữ nghĩa

Encoder	Mã hoá (s)	AUC 1 trực	AUC gộp
CafeBERT	34,9	0,689	0,867
E5 (multilingual-base)	21,9	0,722	0,887
BGE-M3 (đối chứng)	69,6	0,719	0,898

Table 2: So sánh encoder trên ViSFD, $n_topics = 40$. AUC trung bình trên 11 khía cạnh gốc.

mới.

6 Đề xuất ứng dụng

Công thức suy luận tài liệu mới $\hat{S} = \hat{X}C^\top$ (Công thức 7) cho phép chấm điểm văn bản mới theo thời gian thực, không cần huấn luyện lại. Nhóm dựng thử hai ứng dụng chạy thật trên các checkpoint đã huấn luyện ở Mục 5.

Ứng dụng 1: Bảng điều khiển phát hiện bất thường. Với một luồng bình luận mới, nhóm so điểm trung bình theo lô trên từng trực với phân phối huấn luyện bằng kiểm định z hai mẫu; trực vượt ngưỡng được cảnh báo, kèm tên khía cạnh nếu trực đó đã hiệu chỉnh nhãn ngoại tuyến qua phương pháp AUC ở Mục 5. Trên kịch bản mô phỏng pin quá nhiệt/phát nổ (51 bình luận giả lập), hệ thống bắt đúng tín hiệu: trực mạnh nhất $z = -12,79$ (gấp gần bốn lần trực mạnh nhì), với từ khoá *nóng, nóng bỏng, tản nhiệt, nhiệt*. Đáng chú ý, nhãn hiệu chỉnh ngoại tuyến gần cho trực này lại là STORAGE (AUC=0,71) chứ không phải BATTERY – cho thấy phát hiện bất thường (dựa trên độ lệch thống kê) hoạt động tốt hơn hẳn việc gán đúng tên khía cạnh.

Ứng dụng 2: Định tuyến câu hỏi cho tổng đài ngân hàng. Một server FastAPI/WebSocket (đóng gói Docker) nạp checkpoint S^3 huấn luyện trên UTS2017_Bank (2.471 câu hỏi, 14 nhãn phòng ban thật), định tuyến câu hỏi mới bằng đúng phép chiếu $\hat{S} = \hat{X}C^\top$, đã kiểm chứng bằng client thật (server/simulate.py). Bảng 3 là AUC định tuyến trên đúng checkpoint server đang dùng: 6/12 nhãn đủ mẫu đạt $AUC \geq 0,75$ chỉ với quy tắc 1-trực hiện dùng (đơn giản, không cần huấn luyện thêm classifier), toàn bộ 12/12 nếu gộp trực bằng hồi quy logistic – đánh đổi thật giữa độ trễ và độ chính xác. Một số

Phòng ban (nhãn)	AUC 1 trực	AUC gộp
CARD	0,830	0,917
CUSTOMER_SUPPORT	0,626	0,900
DISCOUNT	0,740	0,858
INTEREST_RATE	0,796	0,918
INTERNET_BANKING	0,848	0,917
LOAN	0,784	0,941
MONEY_TRANSFER	0,806	0,887
OTHER	0,720	0,856
PAYMENT	0,789	0,837
PROMOTION	0,725	0,868
SAVING	0,711	0,755
TRADEMARK	0,726	0,944

Table 3: AUC định tuyến câu hỏi ngân hàng trên UTS2017_Bank, $n_topics = 30$.

phòng ban còn dùng chung một trực (ví dụ CUSTOMER_SUPPORT và INTEREST_RATE cùng ánh xạ vào Topic 13), là hạn chế thật của độ phân giải mô hình, không phải lỗi cài đặt.

7 Kết luận

Báo cáo tái lập S^3 (Kardos et al., 2025) cho tiếng Việt và mở rộng theo bốn hướng: (1) giải quyết khác biệt kỹ thuật bắt buộc (tách từ tiếng Việt) để pipeline hoạt động đúng trên một ngôn ngữ đơn lập; (2) xây dựng và chạy thật một benchmark 480 lần trên bốn kho ngữ liệu tiếng Việt, xác nhận S^3 dẫn đầu coherence/diversity và đạt tốc độ fit chỉ đứng sau NMF nhờ tái sử dụng vocabulary đã mã hoá và suy ba biến thể từ một phép phân rã FastICA duy nhất; (3) đề xuất một phương pháp đánh giá độ chính xác bằng AUC so trực ICA với nhãn thật – điều paper gốc chủ động không làm; (4) dựng thử và chạy thật hai ứng dụng khai thác khả năng suy luận tài liệu mới của S^3 , đồng thời phát hiện một hạn chế thật của cách hiệu chỉnh nhãn ngoại tuyến.

Hạn chế

Benchmark định lượng (Mục 4) dùng chỉ số coherence nội tại (WEC-in/ C_NPMI), không

đo độ chính xác so với nhãn thật; bốn seed chỉ đo được độ nhạy hẹp; baseline được cài đặt lại, không dùng mã nguồn gốc; tốc độ ở Bảng 1 là fit-only, chi phí mã hoá tài liệu (chiếm phần lớn thời gian pipeline đầy đủ) trình bày riêng ở cuối mục. Đánh giá bằng AUC (Mục 5) có cỡ mẫu kiểm định nhỏ, một số khía cạnh ViSFD rất ít tài liệu dương (STORAGE 132/11.122), và không đánh giá được độ ổn định của trục qua nhiều seed. Hai ứng dụng (Mục 6) dùng quy tắc 1-trục đơn giản (AUC thấp hơn rõ rệt so với gộp trục), một số phòng ban dùng chung trục, và mới kiểm thử trên kịch bản mô phỏng/dữ liệu có sẵn. Cuối cùng, thực nghiệm giới hạn ở tiếng Việt và không tinh chỉnh siêu tham số (tránh p-hacking), nên kết quả phản ánh cấu hình mặc định.

References

- Dimo Angelov. 2020. Top2Vec: Distributed representations of topics.
- Federico Bianchi, Silvia Terragni, and Dirk Hovy. 2021. Pre-training is a hot topic: Contextualized document embeddings improve topic coherence. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*, pages 759–766.
- David M. Blei, Andrew Y. Ng, and Michael I. Jordan. 2003. Latent Dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022.
- Ricardo J. G. B. Campello, Davoud Moulavi, and Jörg Sander. 2013. Density-based clustering based on hierarchical density estimates. pages 160–172.
- Scott C. Deerwester, Susan T. Dumais, Thomas K. Landauer, George W. Furnas, and L. L. Beck. 1988. Improving information retrieval using latent semantic indexing.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*.
- Maarten Grootendorst. 2022. BERTopic: Neural topic modeling with a class-based TF-IDF procedure.
- Aapo Hyvärinen and Erkki Oja. 2000. Independent component analysis: Algorithms and applications. *Neural Networks*, 13(4):411–430.
- Christian Jutten and Jeanny Herault. 1991. Blind separation of sources, part I: An adaptive algorithm based on neuromimetic architecture. *Signal Processing*, 24(1):1–10.
- Márton Kardos, Jan Kostkan, Kenneth Enevoldsen, Arnault-Quentin Vermillet, Kristoffer Nielbo, and Roberta Rocca. 2025. S³ – semantic signal separation. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 633–666, Vienna, Austria. Association for Computational Linguistics.
- Leland McInnes and John Healy. 2018. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.
- Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992.
- Xiaobao Wu, Xinshuai Dong, Thong Nguyen, and Anh Tuan Luu. 2023. Effective neural topic modeling with embedding clustering regularization.
- Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. 2024. FASTopic: A fast, adaptive, stable, and transferable topic modeling paradigm.